Formalnie zweryfikowane algorytmy w Coqu: koncepcje i techniki

Wojciech Kołowski

27 września 2021

1 Historia

2 Streszczenie pracy

Podsumowanie i co dalej

Geneza pracy

- Około połowy 2017 roku postanowiłem sformalizować sobie kilka algorytmów i struktur danych. Tak powstał projekt żyjący pod adresem https://github.com/wkolowski/coq-algs
- W semestrze zimowym 2017/2018 brałem udział w kursie Algorytmy Funkcyjne i Trwałe Struktury Danych (czy jak on tam się zwał), który skłonił mnie do sięgnięcia po książkę Okasakiego i próbę sformalizowania tego, co w niej znajdę.
- Przez kolejne +- dwa i pół roku projekt ewoluował i działy się w nim różne rzeczy, takie jak badania nad spamiętywaniem czy dowodzeniem przez reflekcję.

Skad odkrycia?

- Pewnego razu postanowiłem sformalizować pokaźny wachlarz przeróżnych algorytmów sortowania.
- Podjąłem się go częściowo z nudów, a częściowo żeby nieco systematyczniej zbadać, jak trudno (lub łatwo) formalizuje się algorytmy w Coqu i dowodzi ich poprawności.
- Wcześniejsze formalizacje algorytmów w tym projekcie nie dawały dobrej odpowiedzi na to pytanie, bo dotyczyły przypadkowo dobranych problemów, a rozwiązania pochodziły głównie z ksiażki Okasakiego.

Algorytmy sortowania motorem napędowym nauki

- Spora liczba algorytmów i jeszcze większa mnogość ich wariantów bardzo szybko wymusiły wysoce abstrakcyjne i modularne podejście, a potężny system typów Coqa umożliwił (niemal) bezproblemową realizację tej wizji.
- W miarę postępów formalizacji poznałem też całą masę uniwersalnych prawidłowości, które następnie przekułem w pracy na tytułowe koncepcje i techniki.
- Ostatecznie przekonałem się, że dla wprawnego użytkownika Coqa, uzbrojonego w moje koncepcje i techniki, dowodzenie poprawności algorytmów jest niewiele trudniejsze niż sama ich implementacja (choć jest dużo bardziej pracochłonne).
- Co więcej, zarówno implementacja jak i weryfikacja stają się łatwiejsze, gdy rozważamy je razem.



Pareto wiecznie żywy

- Porównanie algorytmów sortowania okazało się więc być strzałem w dziesiatke.
- Zadziałała też niezawodna zasada Pareto: mimo, że znaczna większość czasu i kodu poświęcona została podstawowym strukturom danych takim jak kolejki, sterty czy samobalansujące się drzewa wyszukiwań, to największym źródłem odkryć i najbardziej istotnym dla napisania pracy elementem projektu było właśnie porównanie algorytmów sortowania.

Motywacje

- Poznawszy wspaniałe techniki radzenia sobie z formalizacją algorytmów stosowalne we wszystkich w zasadzie językach z typami zależnymi, postanowiłem podzielić się nimi ze światem.
- Głównym celem pracy było bardzo przyjazne i dostępne dla zwykłych śmiertelników opisanie tego wszystkiego, w formie tutorialowej zbliżonej stylem do najlepszych dydaktycznie znanych mi postów na blogach.

Abstrakt

Omawiamy sposoby specyfikowania, implementowania i weryfikowania funkcyjnych algorytmów, skupiając się raczej na dowodach formalnych niż na asymptotycznej złożoności czy faktycznej wydajności. Prezentujemy koncepcje i techniki, obie często opierające się na jednej kluczowej zasadzie – reifikacji i reprezentacji, za pomocą potężnego systemu typów Coga, czegoś, co w klasycznym, imperatywnym podejściu jest nieuchwytne, jak przepływ informacji w dowodzie czy kształt rekursji funkcji. Nasze podejście obszernie ilustrujemy na przykładzie quicksorta. Ostatecznie otrzymujemy solidną i ogólną metodę, którą można zastosować do dowolnego algorytmu funkcyjnego.

Jak sformalizować funkcyjny algorytm?

- Praca prezentuje 15 technik przydatnych przy formalizacji algorytmów funkcyjnych.
- Liczba 15 jest trochę naciągana, zresztą nie o ilość chodzi.
- Najlepiej rozumieć te techniki jako podpunkty uniwersalnego planu, który prowadzi nas od problemu do formalnie zweryfikowanego algorytmu, który go rozwiązuje.

Znajdź specyfikację problemu (sekcja 1.6 i rozdział 2)

- #0: Dobra specyfikacja jest abstrakcyjna i prosta w użyciu.
- #1: Dobra specyfikacja określa unikalny obiekt.
- #2: Patchworkowa specyfikacja może zostać ulepszona przy użyciu defunkcjonalizacji (czyli przy użyciu definicji induktywnych zamiast kwantyfikacji uniwersalnej, implikacji i funkcji).
- #3: Czasem można znaleźć lepszą specyfikację skupiając się na innym aspekcie zagadnienia.

Znajdź algorytm, który rozwiązuje problem

- Łatwiej powiedzieć niż zrobić.
- Praca nie porusza tematyki wymyślania czy projektowania algorytmów - zakładamy, że formalizujemy znany już algorytm.

Zaimplementuj abstrakcyjny szablon algorytmu (rozdział 3)

- #4: Przy implementacji pierwszego szablonu nie przejmuj się terminacją.
- #6: Typy parametrów szablonu powinny zawierać wystarczająco evidence (żeby np. nie popaść w ślepotę boolowską), ale nie za dużo.
- #7: Jeżeli implementujesz wiele szablonów na raz (wielu powiązanych algorytmów), ich współdzielone komponenty powinny być parametrami szablonu. Pozostałe komponenty powinny być jego polami.

Udowodnij terminację i poprawność (rozdziały 4 i 5)

- #8: Użyj Metody Induktywnej Dziedziny (to mój rebranding metody Bove-Capretta) żeby zdefiniować lepszy szablon algorytmu, którego terminację łatwo udowodnić.
- #12: W dowodzeniu niesamowicie przydatna jest technika proof by admission, czyli formalny odpowiednik dowodu przez machanie rękami. W skrócie: jeżeli nie potrafisz czegoś udowodnić, załóż że to prawda. Później udowodnij lemat, który wypełni tę lukę, albo przyjmij dodatkowe założenie.
- #9: Dowód terminacji sprowadza się do indukcji dobrze ufundowanej – wystarczy znaleźć jakąś rozsądną relację dobrze ufundowaną lub miarę.
- #11: Dowód poprawności szablonu sprowadza się do indukcji funkcyjnej.

Dostarcz domyślną implementację (rozdziały 5 i 3)

- #5: Dostarcz domyślną implementację.
- #10: Upewnij się, że domyślna implementacja może zostać uruchomiona bez dowodzenia czegokolwiek (terminacji/poprawności) i że terminująca implementacja może zostać uruchomiona bez dowodzenia poprawności.
- #13: Jeżeli twoja domyślna implementacja jest zbyt abstrakcyjna, dostarcz bardziej konkretną wersję.
- #14: Do zdefiniowana domyślnej i konkretnej implementacji użyj type-driven development.

Główna kontrybucja pracy

- Główną kontrybucją pracy jest systematyzacja wielu technik, ich synteza w spójną metodę i zastosowanie tej metody konkretnie do problemu formalizacji algorytmów funkcyjnych.
- Uwaga: nie przypisuję sobie odkrycia w zasadzie żadnej z opisanych przeze mnie koncepcji i technik – część była znana już wcześniej, część ma status pewnego folkloru, a część jest na tyle nieuchwytna, że trzeba je wymyślić na nowo, żeby porządnie je zrozumieć.

Pomniejsze kontrybucje

- Udało mi się w przyjazny i zrozumiały sposób opisać także wiele znanych już technik, które dotychczas były nieopisane lub były opisane słabo.
- Indukcja funkcyjna, elegancka metoda dowodzenia właściwości funkcji rekurencyjnych, nie została nigdzie opisana w sposób przyjazny dla początkujących.
- Metoda Bove-Capretta (co za okropna nazwa!) została opisana w wielu pracach, ale nie są one przyjazne dla początkujących.
- Type-driven development został przyjaźnie opisany, ale książka jest płatna i trochę przeterminowana.
- Spamowanie taktyką admit nie zostało nigdzie opisane jako systematyczna metoda dowodzenia i nie ma nawet oficjalnej nazwy (ja nazwałem to proof by admission), a jego związki z Hole-driven development są nie do końca oczywiste.

Co dalej - ogólnie

- Zaprezentowane w pracy podejście do algorytmów funkcyjnych nie jest kompletne i można je rozszerzyć i poprawić.
- Nie znam żadnej ogólnej metody wymyślania specyfikacji.
- Pominięte zostały metody wymyślania/projektowania algorytmów, gdyż mieleniem ich zajmują się wszystkie możliwe kursy i książki, np. klasyczna książka Okasakiego i niedawno wydana Algorithm Design with Haskell.
- Analiza złożoności mogłaby także nieco zyskać na formalnym podejściu, choćby dlatego że możemy formalnie dowodzić zależności rekurencyjnych. Z drugiej strony analiza komplikuje się przez problemy związane np. z obecnością predykatu dziedzinowego.

Co dalej - terminacia

- Wspomniałem o problemach standardowej Metody Induktywnej Dziedziny z funkcjami z zagnieżdżoną rekursją i rekursją wyższego rzędu, i jak sobie z tym poradzić, ale nie pokazałem, jak dokładnie należy to zrobić.
- Nie omówiłem żadnych metod konstruowania relacji dobrze ufundowanych.
- Nie omówiłem też alternatywnych metod dowodzenia terminacji jako HORPO (Higher Order Recursive Path Ordering) czy Size-Change Principle.
- Milczałem też o algorytmach korekurencyjnych i dowodzeniu ich produktywności, choć to temat raczej badawczy niż dvdaktvczno-folklorystvczny.

Co dalej - bujanie w chmurach

- Zdaje się, że istnieje linia badań nad "obliczaniem" algorytmu ze specyfikacji za pomocą rozumowań równaniowych. W połączeniu z techniką wymyślania specyfikacji byłoby to naprawdę potężne combo.
- Ciekawą rzeczą jest Kombinatoryka Analityczna, która pozwala obliczyć liczbę struktur (np. drzew) danego rodzaju z samej definicji typu induktywnego, dzięki czemu stanowi pomost między specyfikacją a analizą złożoności.
- Testowanie może się wydawać zbędne, jednak property-based testing jest bardzo dobry w znajdowaniu kontrprzykładów, co może znacznie skrócić czas od popełnienia błędu do wykrycia go moglibyśmy zrobić to już na etapie domyślnej implementacji, czyli niedługo po zaimplementowaniu pierwszego szablonu, zamiast dopiero na końcu, przy dowodzie poprawności.